INT6163 高级数据分析个人作业

题目二：网上零售的购物篮分析与客户分群

1. 问题定义

本研究面向一家英国在线礼品零售商，目标是从两年交易记录中回答两个业务问题：第一，哪些商品经常一起购买，从而支持交叉销售、组合促销和网页推荐；第二，客户可以分为哪些具有不同价值和流失风险的群体，从而采用差异化营销策略。研究成功标准为：完成可复现的数据清洗；比较至少两个最小支持度下的关联规则；用 RFM 指标完成客户分群并用层次聚类检查稳定性；针对不同客户群重新挖掘规则，并将结果转化为可执行建议。

2. 数据与预处理

数据集为 Chen（2019）的 UCI Online Retail II，包含 2009-12-01 至 2011-12-09 的英国在线礼品零售交易。Notebook 从原始 Excel 下载包合并两个工作表。为控制 Apriori 的内存和运行时间，主分析默认只保留英国客户；这会牺牲跨国客户的外推性，但保留更一致的市场、物流和价格环境。原始数据共有 1,067,371 条记录。清洗时删除 19,494 条取消订单、242,257 条缺少 Customer ID 的记录、71 条价格小于等于零的记录和 3,990 条非商品 StockCode 记录；英国筛选进一步删除 78,060 条非英国记录。最终保留 723,499 条记录、33,360 笔订单和 5,334 位客户。数据中没有数量小于等于零的有效记录。金额定义为 Quantity × Price。

3. 关联规则方法

以 Invoice 为交易、Description 为商品项构造交易—商品矩阵，同一发票中的重复商品只保留为一次出现。分别使用 min_support=0.02 和 0.01 的 Apriori，报告频繁项集数量、规则数量和运行时间。规则筛选 lift>1 且 confidence>=0.2，按 lift、confidence 和 support 排序。support 表示商品组合覆盖的交易比例，confidence 表示购买前件后购买后件的条件概率，lift 表示该条件概率相对于后件基准购买率的提升倍数。高 lift 但极低 support 的规则可能是偶然组合；同一系列、颜色或尺寸的组合也可能是平凡规则。因此最终推荐不能只看 lift，还应结合销量、毛利、库存和 A/B 测试结果。

4. RFM 客户分群

以数据末日后一天为观察基准，Recency 为距最近购买的天数，Frequency 为发票数，Monetary 为总消费金额。由于 Frequency 和 Monetary 通常右偏，先做 log1p 变换，再标准化。对 K=2 至 8 计算肘部曲线和轮廓系数，选择轮廓系数较高且业务上可解释的 K。K-means 输出每个群体的客户数、RFM 均值和收入贡献，并根据“近期/高频/高消费”特征命名为高价值忠诚客户、高频但有流失风险、一般客户或低价值/新客户。Ward 层次聚类及树状图用于检查 K-means 分群是否具有稳定的层次结构。

5. 结果解释与营销建议

在交易—商品矩阵中保留至少出现 5 次的商品后，矩阵为 33,360 笔交易 × 4,578 个商品。min_support=0.02 得到 181 个频繁项集和 18 条规则，用时约 0.25 秒；min_support=0.01 得到 713 个频繁项集和 350 条规则，用时约 0.61 秒。0.02 阈值下最高 lift 规则为 “SWEETHEART CERAMIC TRINKET BOX → STRAWBERRY CERAMIC TRINKET BOX”，support=0.0227、confidence=0.6892、lift=13.8745；其次为两种木质相框，lift=11.7090。它们具有明确的同系列/互补关系，但也说明最高 lift 规则可能是商品系列效应，不应直接等同于增量销售。

RFM 的轮廓系数在 K=2 时最高（0.441），因此选择两个客户群。高价值忠诚客户有 2,141 人，平均 Recency=52.08 天、Frequency=12.47 笔、Monetary=£5,939.94，收入贡献 £12,717,421.86；低价值/新客户有 3,193 人，平均 Recency=303.48 天、Frequency=2.09 笔、Monetary=£580.73，收入贡献 £1,854,257.77。层次聚类树状图提供了与二分结构相符的稳定性检查。规则重挖掘显示，高价值客户规则最多（42 条），其最高 lift 规则为两种 Regency 茶杯碟，lift=28.1843；低价值/新客户仅得到 8 条规则，较明显的是两种 Baking Set，lift=10.4364。

Notebook 会输出支持度阈值比较表、lift 最高的前十条规则、各客户群的 RFM 概况和各客户群的前五条规则。业务解释应优先采用“较高 support + 较高 confidence + 可执行商品关系”的规则，而不是机械选择最高 lift。对高价值忠诚客户，建议使用高覆盖率互补商品进行个性化推荐和高毛利套装，减少不必要折扣；对低价值/新客户，建议使用低门槛组合、免邮门槛和第二单推荐提升 Frequency。群组规则比较可以识别“所有客户共有”的组合与“特定客户群独有”的组合，后者更适合定向投放。

6. 核心问题回答

最高提升度的规则是否一定有商业价值？ 不一定。lift 会偏好后件本身很少见的组合，样本量太小时估计不稳定；同系列商品之间的高 lift 也可能只是商品目录结构造成的平凡关系。商业采用前必须检查 support、绝对交易数、库存、利润和实验增量。

哪个客户群贡献最多收入却最容易流失？ 本次 K=2 结果没有出现“收入贡献最高且 Recency 也最高”的同一群体：高价值忠诚客户贡献约 87.3% 收入且平均 52 天未购买，低价值/新客户平均 303 天未购买但只贡献约 12.7% 收入。因此严格回答是：高价值忠诚客户贡献最多收入，但低价值/新客户表现出更强的流失信号；管理层应对高价值客户做预防性维护，同时对低价值/新客户做低成本唤回测试。若业务特别需要识别“高价值流失客户”，应增加第三个聚类或单独按 Monetary 分位数与 Recency 分位数组合筛选。

7. 局限与伦理

批发客户的大额、多件购买会显著影响规则和 Monetary；应在后续版本中按客户类型分层。圣诞前销售高峰会造成季节性规则，必须按月份或节日窗口复核。两年数据不能保证长期稳定，也无法确定促销的因果效果。缺失 Customer ID 的订单被删除，可能造成客户结构偏差。客户交易画像应遵循最小化原则、透明告知和访问控制，只用于合理的推荐与客户服务，不应推断敏感属性或将高风险标签用于不公平限制。

参考文献

Chen, D. (2019). *Online Retail II*. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.).

McKinney, W. (2022). *Python for Data Analysis* (3rd ed.).

生成式 AI 使用声明

本作业使用生成式 AI 协助组织分析流程、编写和调试 Python Notebook 初稿、检查报告表述。数据清洗、模型运行、结果核对、图表解释和最终提交内容应由作者在本地运行 Notebook 后复核并负责。